### НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Факультет программной инженерии и компьютерной техники

# Системы искусственного интеллекта Лабораторная работа № 3

Выполнил студент

Кузнецов Максим

Группа № Р33131

Преподаватель: Авдюшина Анна Евгеньевна

### Задание:

- 1. Датасет с классификацией грибов -- https://archive.ics.uci.edu/ml/datasets/Mushroom
- 2. Отобрать случайным образом sqrt(n) признаков
- 3. Реализовать без использования сторонних библиотек построение дерева решений (numpy и pandas использовать можно)
- 4. Провести оценку реализованного алгоритма с использованием Accuracy, precision и recall
- 5. Построить AUC-ROC и AUC-PR

#### Код программы, реализующий данную задачу:

```
import pandas as pd
import numpy as np
from sklearn.model selection import train test split
from sklearn.metrics import accuracy score, precision recall curve,
roc curve, auc, average precision score, precision score, recall score,
RocCurveDisplay, PrecisionRecallDisplay
import matplotlib.pyplot as plt
    '13': 'stalk-surface-below-ring',
```

```
def draw plt(predict arr, expect arr):
   y true = np.array([0 if x == 'p' else 1 for x in predict arr])
    y score = np.array([0 if x == 'p' else 1 if x == 'e' else '-1' for x
in expect arr])
    fpr, tpr, = roc curve(y true, y score)
    roc display = RocCurveDisplay(fpr=fpr, tpr=tpr).plot()
   precision, recall, = precision recall curve(y true, y score)
   pr display = PrecisionRecallDisplay(precision=precision,
recall=recall).plot()
   auc roc = auc(fpr, tpr)
   auc pr = average precision score(y true, y score)
    fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 8))
   roc display.plot(ax=ax1)
   pr display.plot(ax=ax2)
   plt.show()
def analyze(predict arr, expect arr):
   print("Recall:", recall score(expect arr, predict arr,
average="micro"))
   print("Accuracy:", accuracy score(expect arr, predict arr))
   print("Precision:", precision score(expect arr, predict arr,
average="micro"))
def get entropy(names):
   entropy = 0
   for name in set(names):
       p = names[names == name].shape[0] / names.shape[0]
        entropy -= p * np.log2(p)
    return entropy
def get condition entropy(names, cl):
    entropy = 0
   for name in set(names):
       c = cl[names == name]
       tmp ent = get entropy(c)
       p = c.shape[0] / cl.shape[0]
       entropy += p * tmp_ent
    return entropy
def get split info(names, cl):
   info = 0
   for name in set(names):
       c = cl[names == name]
       p = c.shape[0] / cl.shape[0]
        info -= p * np.log2(p)
    return info
def gain info(names, cl):
```

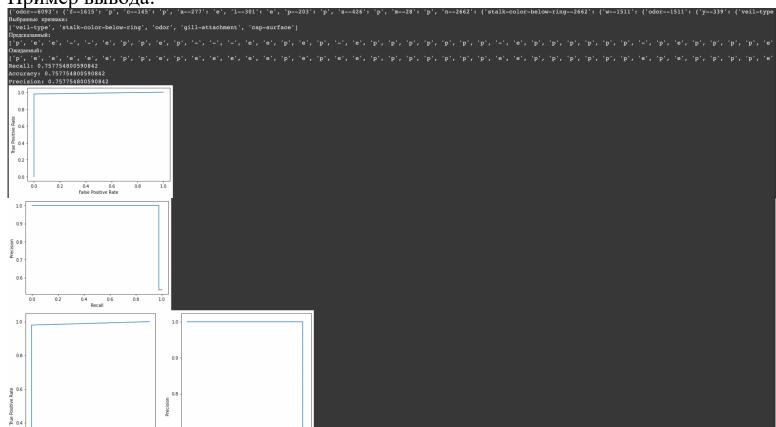
```
return (get entropy(names) - get condition entropy(names, cl)) /
(get split info(names, cl)+0.0000001)
def built tree(names, cl, depth=1):
   class 1, class 2 = set(c1)
   max = class_1 if np.sum(cl == class_1) > np.sum(cl == class_2) else
class 2
   if depth > 10:
       return max
    if len(names[0]) == 0:
   index best = 0
    for name index in range(len(names[0])):
        gain = gain info(names[:, name index], cl)
           max gain = gain
   sub T = {} {} {}
    for best name in set(names[:, index best]):
        sub y = cl[names[:, index best] == best name]
       sub X = np.delete(sub X, index best, 1)
       sub T[best name + "--" + str(len(sub X))] = built tree(sub X,
sub y, depth + 1)
   T[cols name[index best] + "--" + str(len(names))] = sub T
def make_pred(x, tree=None):
    if x.ndim == 2:
       res = []
            res.append(make_pred(x_element))
        return res
```

```
if not tree:
        tree = main tree
    key = list(tree.keys())[0]
    name = key.split("--")[0]
       index = cols name.index(name)
    except ValueError:
    curr tree = tree[key]
    for k in curr tree.keys():
        if k.split("--")[0] == x[index]:
            key = k
            curr tree = curr tree[key]
        return make pred(x, curr tree)
    else:
data = pd.read csv("agaricus-lepiota.data", header=None)
Names = data.iloc[:, 1:]
Names = \overline{\text{Names.sample}(n=5, axis=1)}
cols = Names.columns.tolist()
cols_new = [column_names.get(str(x)) for x in cols]
global cols name
main tree = dict()
cols name = cols new
Names = Names.values
Class = Class.values
Names_train, Names_test, Class_train, Class_test = train_test_split(Names,
Class, random_state=0)
main_tree = built_tree(Names_train, Class_train)
predict = make pred(Names test)
```

```
print(main_tree)
print("Выбранные признаки:")
print(cols_new)
print("Предсказанный:")
print(predict)
print("Ожидаемый:")
print(Class_test.tolist())

analyze(predict, Class_test)
draw plt(predict, Class test)
```

Пример вывода:



# Вывод -- в результате данной работы я:

- Познакомился с методом классификации «деревья решений»
- Применил знания математики для написания алгоритма C4.5, улучшенную надстройку